

1.03.04 - Ciência da Computação / Sistemas de Computação

APLICAÇÃO DE PERCEPTRONS NA SEGMENTAÇÃO DE IMAGENS PARA RECONSTRUÇÃO 3DSamuel F. Santos¹, Cesar A. Bravo Pariente², Isaque S. Passos Ribeiro³

1. Estudante de Ciência da Computação da UESC

2. Professor da UESC - Departamento de Engenharias e Computação/Orientador

3. Estudante de Ciência da Computação da UESC

Resumo

Esse projeto visa o desenvolvimento de 3 Perceptrons em baixo nível, e sua aplicação em um conjunto massivo de dados para demonstrar a capacidade computacional do Perceptron, e contribuir para a produção de material de apoio nas áreas de sistemas inteligentes e redes neurais. A abordagem adotada baseia-se no processamento de imagens, para classificação de regiões de interesse do conjunto de dados. Para isso, foi utilizado o modelo computacional de Frank Rosenblatt para o Perceptron, que emprega uma função de decisão durante o treinamento para determinar os valores dos pesos sinápticos responsáveis pela classificação. Todo o conjunto de dados é submetido ao processamento dos Perceptrons. Assim, obtêm-se conjuntos de dados com as regiões de interesse devidamente classificadas. E ao fim disto, os resultados são submetidos a reconstrução 3D. Desse modo, o projeto contribui para suprir a demanda por materiais didáticos que auxiliem a compreensão de sistemas inteligentes e redes neurais.

Apoio financeiro: PROBEX – Programa Institucional de Bolsas de Extensão

Introdução

Atualmente, os sistemas inteligentes são uma área tecnológica, voltada ao desenvolvimento de sistemas computacionais capazes de aprender e tomar decisões. Das subáreas, destacam-se as redes neurais, que estudam modelos computacionais inspirados no funcionamento dos neurônios biológicos. Nesse contexto, o Perceptron é um dos componentes fundamentais dessas redes. O "Psychon" idealizado por Warren McCulloch e Walter Pitts (MCCULLOCH; PITTS, 1943), que propuseram as primeiras modelagens do que futuramente seria o Perceptron. Seguidamente, Frank Rosenblatt transformou em um modelo treinável e computável (ROSENBLATT, 1958).

O Perceptron é um classificador linear binário que separa dados em duas classes por meio de uma fronteira de decisão linear. Para isso, utiliza pesos sinápticos, que são valores numéricos associados a cada elemento de um vetor de entrada, indicando a relevância de cada variável. O funcionamento do modelo pode ser dividido em três etapas principais: amostragem, treinamento e classificação. No treinamento o Perceptron utiliza o erro médio quadrático (MSE) como métrica para avaliar a diferença entre a saída produzida pelo modelo e o valor real.

No contexto nacional dos sistemas inteligentes, observa-se a necessidade de um maior acervo de materiais didáticos que auxiliem na compreensão das redes neurais, e abordagens práticas relacionadas ao processamento de imagens. O desenvolvimento de materiais didáticos contribui para a formação acadêmica e no avanço das pesquisas na área de sistemas inteligentes.

Diante disto, o objetivo deste projeto é desenvolver e aplicar o Perceptron em um conjunto massivo de dados, demonstrando sua implementação em baixo nível a partir dos conceitos computacionais e matemáticos que os fundamentam. Assim, foram utilizados os princípios matemáticos de Rosenblatt, onde os pesos sinápticos são definidos no processo de treinamento com função de ativação limiar, para então serem empregados na classificação dos dados. O projeto aborda o desenvolvimento de 3 Perceptrons e suas aplicações em dados do Visible Human Project (National Institute of Health, 1986). Esta abordagem considera o processamento de imagens, realizando a classificação de pixels RGB para regiões de interesse e reconstrução 3D para visualização do conjunto de dados.

Metodologia

Rosenblatt descreve um modelo computacional para o Perceptron, onde é feito o treinamento do neurônio (ROSENBLATT, 1958). Nesse modelo, o Perceptron é descrito como uma unidade capaz de realizar classificação binária a partir da combinação linear de entradas seguida da aplicação de uma função de decisão. O modelo é composto por 3 elementos principais: entradas, um vetor de valores que descreve as características do dado; pesos sinápticos, valores associados a cada entrada que determinam sua influência no processo de classificação; e função de ativação do tipo limiar, onde a soma ponderada das entradas é transformada em uma saída discreta. Após o cálculo da soma ponderada, a função de ativação define a saída do modelo: caso o valor obtido seja maior ou igual ao limiar, o resultado é 1; caso contrário, é 0. Isso caracteriza o Perceptron como um classificador binário. Durante o treinamento, os pesos são ajustados iterativamente com base nos erros de classificação calculados através do MSE, assim, o modelo é treinado a partir de exemplos positivos ou negativos.

A metodologia deste trabalho consistiu na implementação e aplicação de 3 Perceptrons sequencialmente com diferentes funcionalidades. São eles: Perceptron RGB, responsável por realizar a separação da região de interesse com base nos valores de cor no espaço RGB; Perceptron Horizontal, responsável pela separação de ruídos considerando sua distribuição posicional no eixo horizontal; e Perceptron Vertical, análogo ao Perceptron

Horizontal, porém operado verticalmente. No desenvolvimento desses Perceptrons foi utilizado o modelo computacional desenvolvido por Rosenblatt (ROSENBLATT, 1958). Os Perceptrons são organizados em uma estrutura sequencial de processamento, na qual a saída produzida por um Perceptron é utilizada como entrada para o Perceptron subsequente.

Todo o projeto foi desenvolvido utilizando a plataforma Processing, uma plataforma de programação baseada em Java para aplicações de processamento de imagens. O material foi organizado em módulos, que estruturam o funcionamento do Perceptron em três etapas: Amostragem, responsável pela coleta de dados utilizados no treinamento; Treinamento, etapa na qual o modelo computacional é aplicado para gerar os pesos sinápticos; e Classificação, em que os pesos sinápticos obtidos são utilizados para realizar a classificação dos dados.

Para demonstrar as aplicações do Perceptron foi utilizado um conjunto 1871 dados do Visible Human Male (VHM), do Visible Human Project. Esse conjunto é composto por imagens de um corpo humano em cortes anatômicos com espessura de 1 mm. Material com características favoráveis a separação binária. Todas as imagens foram submetidas aos 3 Perceptrons, para obtenção de novos conjuntos de imagens. Para então, essas imagens 2D serem empilhadas na reconstrução 3D, respeitando a posição vertical correspondente a cada corte anatômico.

Todo projeto desenvolvido se encontra no GitHub em: <https://github.com/SamuelFerrc/Perceptrons>

Resultados e Discussão

No processamento das 1.871 imagens, foram gerados quatro novos conjuntos de dados, correspondentes aos resultados obtidos pelos Perceptrons RGB, Horizontal e Vertical, bem como ao processo de remontagem. Esses conjuntos evidenciam a capacidade de classificação individual de cada Perceptron, mas algumas separações mantêm em evidência os ruídos não removidos. Após a execução dos Perceptrons, o conjunto de dados final é submetido a uma etapa de remontagem. Essa reconstrução tridimensional é realizada por meio da geração de arquivos no formato PLY, os quais são posteriormente utilizados no software MeshLab para visualização 3D. Os resultados obtidos demonstram não apenas a delimitação da região de interesse, mas também a revelação de detalhes que não são perceptíveis nas imagens bidimensionais, evidenciando a eficácia da abordagem proposta em realizar a segmentação da região de interesse.

Figura 1 – Etapas do processamento da imagem para segmentação do VHM: (a) imagem original; (b) resultado do processamento com perceptron RGB; (c) separação utilizando Perceptron horizontal; (d) separação utilizando Perceptron vertical.





Figura 2 – Remontagem do VHM: (a) visão frontal; (b) visão traseira; (c) visão lateral direita; (d) visão lateral esquerda; (e) visão traseira rotacionada; (f) visão frontal rotacionada.



Entretanto, estes resultados também evidenciam limitações que estão diretamente relacionadas às restrições teóricas do Perceptron. Conforme discutido por Marvin Minsky (MINSKY; PAPERT, 1969), o modelo do Perceptron é incapaz de resolver problemas que não sejam linearmente separáveis, como o clássico problema do XOR. Essa limitação teórica manifesta-se, na prática, na dificuldade do modelo em capturar padrões mais complexos presentes nos dados analisados. No contexto deste trabalho, essa restrição é observada na presença de falsos positivos e falsos negativos. Os falsos positivos correspondem a pixels indevidamente classificados como pertencentes à região de interesse, enquanto os falsos negativos representam a perda de informações relevantes. Tais ocorrências indicam que, mesmo com ajustes nos critérios de separação, o modelo não consegue eliminar completamente os erros de classificação, impedindo que o MSE atinja o valor mínimo possível, igual a zero. Esse comportamento confirma experimentalmente as limitações estruturais do Perceptron apontadas por Minsky.

Mediante isso, os novos conjuntos de dados tendem a apresentar pequenos ruídos devido a imprecisão dos pesos sinápticos, um resultado direto das limitações do treinamento apontadas por Minsky. Diante desse cenário, torna-se necessário adotar estratégias que minimizem o erro médio quadrático, visando aprimorar a

precisão do modelo. Nesse contexto, a utilização de conjuntos de amostras mais representativas e refinadas contribui diretamente para a melhoria do desempenho, reduzindo os valores de MSE e elevando a acurácia da classificação. Em contrapartida, o treinamento excessivo do modelo pode ocasionar o fenômeno conhecido como overfitting (sobreajuste). Esse problema ocorre quando o Perceptron se ajusta demasiadamente aos dados de treinamento, passando a aprender não apenas os padrões relevantes, mas também ruídos e particularidades específicas do conjunto utilizado. Como consequência, o modelo apresenta bom desempenho durante o treinamento, porém tende a generalizar de forma inadequada para novos dados, comprometendo a precisão da classificação ao não reconhecer adequadamente características presentes em imagens que não fizeram parte do conjunto de treinamento.

Conclusões

Todos os objetivos propostos pelo projeto foram alcançados, através do desenvolvimento dos Perceptrons aplicados para classificação no contexto de processamento de imagens, bem como pela aplicação prática desses algoritmos em um conjunto de dados público. A partir dessa abordagem, tornou-se possível realizar a reconstrução tridimensional da superfície da pele do VHM contida no conjunto de dados, permitindo a visualização mais detalhada das características e propriedades do objeto de estudo.

Ressalta-se que todos os algoritmos de amostragem, treinamento e classificação dos Perceptrons, foram desenvolvidos na plataforma Processing, e que o material produzido está integralmente disponibilizado de forma pública, visando contribuir para a reprodutibilidade e disseminação do conhecimento. Sendo assim, esses resultados contribuem para auxiliar na compreensão dos fundamentos de redes neurais e de sistemas inteligentes.

O repositório do projeto <https://github.com/SamuelFerrc/Perceptrons> reúne um guia detalhado sobre a utilização e o desenvolvimento dos Perceptrons, apresentando também a sequência completa de execução necessária para a reprodução dos resultados obtidos. Além disso, os códigos disponibilizados servem como apoio para o entendimento do funcionamento computacional dos Perceptrons, favorecendo seu uso como material de estudo e consulta.

Também foi possível observar, a partir do desenvolvimento deste material, as limitações do Perceptron já descritas em estudos anteriores sobre esse modelo computacional. Entre essas limitações destaca-se a dificuldade de treinamento com dados não linearmente separáveis, o que ocasiona a ocorrência de falsos positivos e falsos negativos, afetando o resultado da classificação.

Diante disso, foram aplicadas técnicas destinadas a minimizar os ruídos presentes na classificação, buscando reduzir os erros e alcançar o menor erro quadrático médio (MSE) possível durante o processo de treinamento.

Como trabalhos futuros, destaca-se a possibilidade de utilização de Perceptrons multicamadas (CARVALHO; BRAGA; LUDERMIR, 1998), que são capazes de resolver problemas envolvendo dados não linearmente separáveis. No presente projeto, optou-se por limitar a implementação ao Perceptron de camada única, com o objetivo de manter o foco didático e produzir um material completo voltado à compreensão dos fundamentos desse modelo.

Referências

- MCCULLOCH, Warren S.; PITTS, Walter. A logical calculus of the ideas immanent in nervous activity. *Bulletin of Mathematical Biology*, v. 52, n. 1/2, 1943.
- ROSENBLATT, Frank. The perceptron: a probabilistic model for information storage and organization in the brain. *Psychological Review*, v. 65, n. 6, 1958.
- MINSKY, Marvin; PAPERT, Seymour. *Perceptrons: an introduction to computational geometry*. Cambridge, MA: MIT Press, 1969.
- NATIONAL INSTITUTE OF HEALTH; VISIBLE HUMAN MALE; NATIONAL LIBRARY OF MEDICINE (NLM), 1986. *Visible Human Male Images*. Index of public/Visible-Human/Male-Images. Disponível em: https://www.nlm.nih.gov/research/visible/visible_human.html
- CARVALHO, André Carlos Ponce de Leon Ferreira de e BRAGA, Antonio de Pádua e LUDERMIR, Teresa Bernarda. *Fundamentos de redes neurais artificiais*. Rio de Janeiro: DCC/IM, COPPE/Sistemas, NCE-UFRJ.